

# 화재 대피경로 예측 시간 단축을 위한 은닉 상태 없는 시계열 신경망

## A time-series neural network with no hidden state for shortening fire escape route prediction time

이 광 엽\*, 김 민 형\*, 정 준 모\*\*★

Kwang-Yeob Lee\*, Min-Hyung Kim\*, Jun-Mo Jeong\*\*★

### Abstract

This paper proposes a deep learning neural network model design and training data generation method for fast evacuation route prediction in indoor fires. Existing LSTM and ConvLSTM-based time series neural networks have a disadvantage in rapid evacuation because they do not produce quick results because they predict the spread of fire by receiving a hidden state. In this paper, prediction results can be made only from past input data without using hidden states and a neural network is proposed. Since the output is determined at any point in time by calculating and using the inputs of the past time points in parallel, a fast evacuation route may be predicted. The proposed neural network integrates TCN and SEN to obtain shorter prediction time by optimizing the spatiotemporal feature extraction process. Compared to the existing LSTM, it showed an improvement of about 6.3% based on  $R^2$  and about 17.7% based on RMSE, shortening the prediction time of more than 10 seconds.

### 요 약

본 논문은 실내 화재에서 빠른 대피경로 예측을 위한 딥러닝 신경망 모델 설계와 학습 데이터 생성 방법을 제안한다. 기존의 LSTM 및 ConvLSTM 기반의 시계열 신경망은 은닉 상태를 전달받아 화재 확산을 예측하기 때문에 빠른 결과를 만들지 못하여 빠른 대피에 단점이 있다. 본 논문에서는 은닉 상태를 사용하지 않고 과거 입력된 데이터만으로 예측 결과를 만들 수 있는 신경망을 제안한다. 과거 시점의 입력을 병렬로 연산하여 사용하여 어떤 시점에서도 출력이 결정되기 때문에 빠른 대피경로를 예측할 수 있다. 제안하는 신경망은 TCN과 SEN을 통합하여 시공간적 특징 추출 과정 최적화로 예측 시간 단축을 얻고자 한다. 기존의 LSTM 대비  $R^2$  기준으로 약 6.3%, RMSE 기준으로 약 17.7% 향상된 성능을 보이며 10초 이상의 예측 시간을 단축하였다.

*Key words : indore fire, fire simulation, Temporal Convolution Networks, Squeeze-and-Excitaion Networks, Deep Learning*

\* Dept. of Computer Eng., Seokyeong University

\*\* Dept. of Electronics Eng., Seokyeong University

★Corresponding author

E-mail : kylee@skuniv.ac.kr, Tel: +82-2-940-7745

※ Acknowledgment

This Research was supported by Seokyeong University in 2024, 2025.

Manuscript received Jun. 5, 2025; revised Jun. 14, 2025; accepted Jun. 24, 2025.

This is an Open-Access article distributed under the terms of the Creative Commons Attribution on-Commercial License(<http://creativecommons.org/licenses/by-nc/3.0>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited.

## I. 서론

야의 화재와는 달리 건물 내부의 화재는 폐쇄된 공간으로 인하여 화재가 빠르게 확산되고 복잡한 구조와 장애물로 인하여 신속한 탈출이 어렵다. 최근 도시의 건물은 점차 고층화되고 대형화되면서 건물 화재는 많은 인명 피해를 초래할 수 있다. 건물에서 화재가 발생하였을 때 화재 확산 범위와 시간 예측을 기반으로 빠른 대피 경로를 제시한다면 인명 피해를 최소화 할 수 있다.

이러한 필요성 때문에 화재 확산예측과 관련하여 많은 연구가 진행 되어왔다. 특히, 머신러닝과 딥러닝 기반 예측 방법은 기존 알고리즘에 비하여 성능이 우수하기 때문에 최근에는 이러한 인공지능을 기반으로 하는 화재 예측 연구가 주류를 이루고 있다.

최근의 건물은 IBS(Intelligent Building System)로 관리되기 때문에 건물 내부의 다양한 센서로부터 실시간 데이터 취득이 가능하여 인공지능 학습 데이터로 사용될 수 있어 인공지능 기반의 건물 화재 예측 기술이 발전할 수 있다.

그러나 기존의 많은 연구들은 화재에서 발생하는 고열의 온도, 일산화탄소, 연기로 인한 가시성 등의 확산 범위와 농도 예측의 정확도에 중점을 두고 있으나 예측 시간 단축에는 문제점을 갖고 있다. 예측 시간 단축은 빠른 대피 경로를 제시하여 화재 피해를 줄일 수 있는 중요한 부분이기 때문이다.

본 논문에서는 센서 데이터를 딥러닝 신경망의 학습 데이터로 사용하여 온도, 일산화탄소, 연기 농도 출력으로 화재 확산 범위를 예측하고 예측 시간을 단축하기 위한 신경망 구조와 예측 모델을 제시한다.

## II. 관련 연구

### 2.1 이미지 기반 연구

화재를 실시간으로 분석하고 예측하는 데 이미지를 이용하는 연구가 오랫동안 진행되었다. [1]에서는 화염과 연기를 분리하여 전처리할 때 화염은 HSV 색 공간 변환으로 색상 영역을 추출하고 Harris 코너 검출기로 화염 영역을 식별하며 연기는 Dark Channel Prior 기법으로 연기 영역을 식별한다.

[2]연구는 CCTV 영상에서 화염을 효과적으로 감지하는 방법을 제안하였다. 기존에는 주로 화염의 색상이나 움직임에만 의존하여 오탐률이 높고, 다양한 환경에서의 적용에 한계가 있어 이미지에서 화염의 특징을 추출하

고, 밀도 기반의 공간 클러스터링을 통해 보다 정확하고 신뢰성 있는 화재 감지를 목표로 하였다.

[3]에서는 연기와 불꽃을 포함한 화재 이미지에서 굴뚝 배출물이나 구름과 같은 화재 유사 객체로 인한 오탐지를 줄이는 데 중점을 두었다.

이미지 기반 연구에서도 화재 오탐률을 낮추기 위해 다양한 인공지능 기법을 사용하고 있다. [1]은 전처리된 화염 및 연기 후보 영역에 대해 Inception-V3 모델을 사용하여 화재 여부를 정확하게 판단한다. [2]에서는 대표적인 비지도 학습 클러스터링 알고리즘으로, 밀도 기반 클러스터링인 DBSCAN(Density Based Spatial Clustering of Applications with Noise)을 통해 화염 후보를 그룹화한다. [3]에서는 YOLOv5 모델의 Neck 부분에 CBAM (Convolutional Block Attention Module)을 추가하여 유사 객체 검출을 하였다.

### 2.2 센서 데이터 기반 연구

이미지를 기반으로 하는 화재 검출 및 확산예측 기술에서는 화재의 주요 구성요소인 화염과 연기를 분리해야 하고 일산화탄소와 같은 독성 가스 요소는 이미지로 검출되지 않기 때문에 오탐률이 높은 단점이 있다. 또한, 이미지 처리시간이 길어서 빠른 대피 경로 제시에 어려움이 있다. 최근 건물들은 IBS로 지능화되면서 다양한 센서가 설치되어 있어 실시간으로 화재와 관련된 데이터를 받을 수 있다. 이러한 요인으로 최근에는 이미지의 단점을 극복한 센서 데이터 기반 연구가 널리 진행되고 있다[4].

센서 데이터 기반 연구에서는 데이터를 LSTM과 같은 시계열 신경망 모델로만 처리하면 공간정보가 부족하여 2차원으로 배치된 센서와 화재의 형태가 잘 반영되지 못하기 때문에 최근에는 ConvLSTM(Convolutional Long Short-Term Memory)[5]이나 TCN(Temporal Convolution Networks)을 사용하여 시공간적 특성이 강한 화재 확산예측에서 빠른 학습과 안정적인 성능을 제공하는 연구가 진행되고 있다.

[6]에서는 다변량 시계열 예측을 위해 M-TCN(Multivariate-TCN) 모델을 제안하였다. M-TCN은 비주기적 데이터에 대한 시퀀스-투-시퀀스 예측을 수행하며, ConvLSTM, TCN, MALSTM-FCN 등과 비교하여 예측 정확도와 일반화 성능에서 우수한 결과를 보였다.

[7]에서는 시계열 데이터의 이상 탐지를 위해 LSTM과 TCN 모델을 비교하였으며 실험 결과, TCN은 LSTM보다 약간 더 나은 성능을 보였으며, 학습 속도에서도 우위

를 접하였다. CNN기반의 TCN은 RNN기반의 LSTM보다 더 안정적이면서 빠른 성능을 제공하였다.

[8]에서는 ConvLSTM을 활용하여 야생 화재의 시공간적 확산을 모델링하였다. ConvLSTM은 기존의 CNN보다 복잡한 지형과 기상 조건에서도 더 정확한 예측을 제공하며, 특히 화재 전선의 위치와 확산 속도를 효과적으로 예측하는 데 강점을 보였다.

[9]에서는 ConvLSTM과 LSTM을 활용하여 야생화재 위험을 예측하였으며, ConvLSTM이 공간적 맥락을 고려하여 더 높은 정밀도와 낮은 오탐률을 보였다. 또한, SHAP, PDPs, IGs 등의 기법을 통해 모델의 예측 결과를 해석하였다.

[10]에서는 SLA-ConvLSTM(Static Location Aware-ConvLSTM) 모델을 제안하여 전 세계적인 화재 위험을 예측하였다. 이 모델은 정적 위치 정보를 고려하여 ConvLSTM의 시공간적 예측 능력을 향상시켰으며, 전통적인 VIT 및 ConvLSTM 모델보다 우수한 예측 성능을 보였다.

### III. 학습 데이터

화재 예측 신경망 모델의 학습에 사용할 데이터를 만들기 위해 센서를 포함하는 건물 모델 설계, 시뮬레이터를 이용한 화재 시나리오 구축, 시뮬레이터 결과에서 화염 온도, 일산화탄소, 연기 농도의 이미지 취득의 순서로 진행된다.

#### 3.1 화재 모델 설계

화재 모델 설계를 위해 사용되는 Revit은 BIM(Building



Fig. 1. Structural diagram with sensors.

그림 1. 센서위치를 포함한 구조도

Information Modeling) 소프트웨어의 파일 형식으로 건물 모델, 설계 정보, 도면을 설계하여 건물의 3D 모델 정보를 만들 수 있다. 3D 모델 정보에는 벽, 바닥, 천장, 창문 등 건물 설계 요소를 담고 있으며 파라메트릭 데이터로 구성요소의 크기, 재질, 수량, 성능 등을 설계에 반영할 수 있다. 본 논문에서는 [5]연구에서 사용된 가로 66m, 세로 53m 높이 3.8m의 크기의 단층 건물을 사용하고 각 바닥 셀(Cell)의 크기는 1m×1m×0.2m로 설정하였다. 모델의 입력이 되는 센서의 배치는 가로 7m, 세로 7.5m 간격으로 총 10×7개를 높이 1m 지점에 설치하였다. 설계된 화재 모델의 건물 구조는 그림 1과 같다.

#### 3.2 학습 데이터 개발

신경망 모델 학습 데이터셋은 화재 시뮬레이션 프로그램인 FDS(Fire Dynamic Simulator)와 Pyrosim을 사용하여 시뮬레이션 방법으로 제작하였다. FDS는 화재의 성장, 연기 확산, 열전달 및 대피 시나리오 분석을 위해 사용되는 시뮬레이터로 건물 실내 구조 정보와 화재 관련 감지 센서를 설정하고 임의의 발화점으로부터 Navier-Stokes 방정식을 근거로 하여, 저속의 화재 흐름(Low Mach Flow)을 수치적으로 해석하여 화염과 연기의 확산을 시뮬레이션한다.

입력 데이터로는 건물 구조, 가연물 정보, 점화 위치/시간, 환기 조건을 설정하고 결과 데이터로는 온도 분포, 연기 농도, 열 방출률, 유동 속도, CO 농도를 이미지로 얻을 수 있다. 이때, 입력 데이터를 학습 데이터로 하고 결과 데이터가 label이 되어 지도학습이 이루어진다.

Pyrosim은 그래픽 기반의 UI를 통해 건축물의 구조, 가연물, 환기 시스템 등을 시각적으로 구성할 수 있어 입력 데이터를 보다 정밀하게 설정할 수 있어 학습 데이터의 신뢰성을 높일 수 있다.

설계된 화재 건물의 Revit파일을 Pyrosim에서 사용할 수 있도록 IFC(Industry Foundation Classes)형식으로 변환해 Pyrosim에 적용하였다. Pyrosim에서는 열 방출률(Heat Release Rate), 연기 농도, 온도 분포 등의 데이터를 그래프로 분석하고, 동영상으로 결과를 저장할 수 있다.

학습 시뮬레이션 데이터는 설계된 화재 건물 모델에서 발화지점을 20개 설정하고 각 발화점에서 10개의 열 방출률(HRR, Heat Release Rate)을 설정하여 총 200개의 학습 시뮬레이션 시나리오를 개발하였다.

#### IV. 신경망 설계

기존 연구에서는 화재 데이터로부터 공간적 특성과 시간적 특성을 효율적으로 추출하기 위한 ConvLSTM 기반의 모델을 제안하였다[5]. ConvLSTM은 컨볼루션 연산을 통하여 공간적 특징을 잘 파악하고 LSTM의 장기 기억 능력을 결합하여 화재 확산의 복잡한 시공간적 패턴을 모델링할 수 있는 구조를 갖고 있다.

ConvLSTM 구조에서는 입력과 이전 은닉 상태 출력을 결합하여 합성곱 연산을 하는데 LSTM의 time-step에 따라 순차 처리를 하고 시간 순서에 따라 내부 상태(hidden state)가 누적되기 때문에 더 정밀한 시간 의존성 모델링이 가능하다. 그러나, 그림 2에서와 같이  $x_n$  입력에 대한 출력을 결정할 때 입력  $x_0$ 부터  $x_{n-1}$ 까지 생성된 hidden state  $h_0 \dots h_{n-1}$ 를 모두 참조하기 때문에 최종 출력을 얻기까지  $n$  단계의 시간이 소요된다. 따라서, ConvLSTM을 이용한 화재 예측에서 1초 간격으로 30개의 센서 데이터를 입력으로 하여 화재확산에 대한 예측 결과는 30초 이후부터 출력이 되기 때문에 화재 발생시 빠른 대피경로 제시하는데 한계가 있다. 일반적인 convolution을 사용하는 ConvLSTM은 공간 중심문제에서는 성능이 좋지만 현재값을 예측하는데 과거값과 미래값을 모두 사용하기 때문에 실시간 예측에서 낮은 판단이 이루어진다.

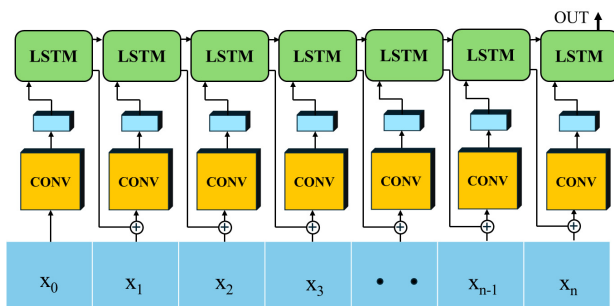


Fig. 2. ConvLSTM structure.

그림 2. ConvLSTM 구조

##### 4.1. 예측시간 단축을 위한 신경망 모델

본 논문에서는 기존 LSTM이나 ConvLSTM 모델의 단점인 긴 예측 시간을 단축하기 위하여 TCN 구조를 기반으로 하였다. TCN은 그림 3과 같이 긴 시계열 네트워크에서 과거 시점의 입력만으로 현재 입력에 대한 출력을 결정한다. 과거 입력이 만든 hidden state를 사용하지 않고 과거 시점의 입력을 병렬로 연산하여 사용하기

때문에 어떤 시점에서도 출력을 결정할 수 있어 빠른 대피 경로를 예측할 수 있다.




Fig. 3. TCN structure.

그림 3. TCN 구조

시계열 예측이 뛰어난 causal convolution을 사용하는 TCN에서 시계열 예측에서는 미래값을 참조하지 않고 과거값만을 사용하기 때문에 실시간 예측이 뛰어나다.

TCN은 Dilated Convolution이란 추출 간격(Dilation)을 조절하여 더 넓은 수용 범위를 갖게 하는 변형 Convolution Layer를 사용한다. 즉 추출 간격을 조절하는 Dilated Causal Convolution을 적용하면 적게 Layer를 쌓아도 넓은 수용 범위를 갖을 수 있는 장점을 갖고 있다. 그림 3은  $d(\text{dilation})=1$  이면서,  $k(\text{kernel})=3$ 인 구조로 현재와 과거 입력 3개가 현재값을 출력하는 예제로 하여 넓은 수용 범위를 보여준다.

본 논문에서는 TCN의 Causal Convolution의 단점인 공간 특성 정보 부족을 보완하기 위해 SEN(Squeeze-and-Excitation Networks)을 적용하였다. SEN은 딥러닝 모델에서 채널 간의 상호 의존성을 효과적으로 모델링하기 위해 제안된 구조다. 이 방법은 특징 맵의 채널별 중요도를 동적으로 조정함으로써 모델의 표현력을 향상시킨다. SEN Block의 구조는 크게 Squeeze 단계와 Excitation 단계가 있다.

Squeeze 단계에선 각 채널의 공간적 특징을 전역 평균 풀링을 통해 하나의 스칼라 값으로 압축한다. 본 논문의 데이터 특성에 맞춰 기존 센서 데이터의 가로축과 세로축에 더해 시간적 차원까지 함께 압축하였다.

Excitation 단계에선 압축된 스칼라값들을 가지고 두 개의 완전 연결 레이어와 ReLU 활성화 함수를 통해 채널

널의 중요도를 계산한다. 이 중요도 가중치는 Sigmoid 활성화 함수를 통해 원래의 특징 맵에 적용되어 중요한 채널을 강조하고 덜 중요한 채널을 억제한다.

#### 4.2. 제안하는 TCN+SEN 모델

본 논문에서 제안하는 화재 예측 모델은 SEN Block을 TCN의 Residual Block 내에 통합하여 시공간적 특징 추출 과정 최적화로 예측 시간 단축을 얻고자 한다. 화재 상황에서는 센서가 측정하는 데이터의 채널별 중요도가 화재의 진행 단계와 공간적 위치에 따라 동적으로 변화한다. SEN Block은 이러한 동적 중요도를 자동으로 학습하여 각 시간-공간 지점에서 가장 정보가 풍부한 채널에 집중할 수 있게 한다. 이는 제한된 센서 데이터로부터 건물 전체의 화재 상황을 예측해야 하는 본 논문에 특히 적합하다.

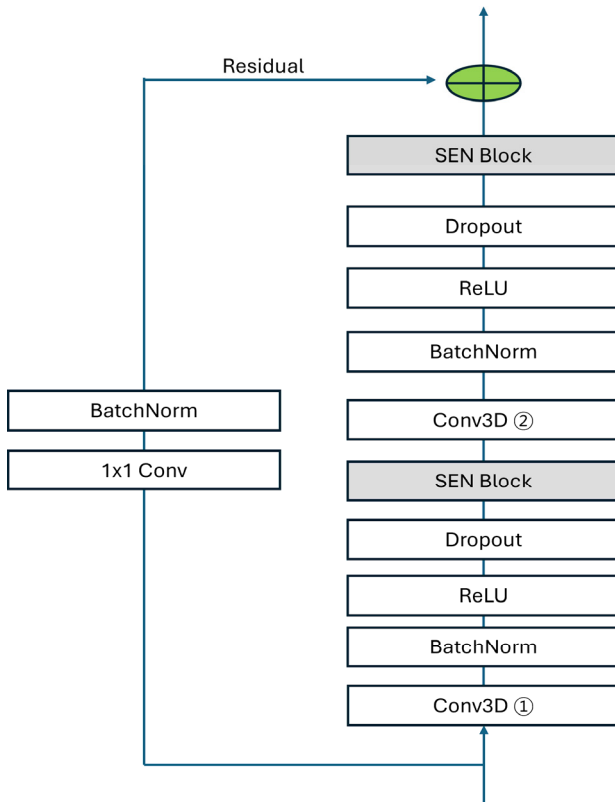


Fig. 4. Residual block combining TCN and SEN.  
그림 4. TCN과 SEN을 결합한 잔차 블록

본 논문에서 제안하는 TCN과 SEN을 결합한 잔차 블록(Residual Block)구조는 그림 4와 같다. ResidualBlock 내에서 첫 번째 SEN 블록은 초기 특징 추출 후 중요한 채널을 강조하여 두 번째 convolution이 더 집중된 학습을 할 수 있도록 한다. 두 번째 SEN 블록은 residual connection 직전에 배치되어 최종 특징 표현을 정제하

고, skip connection과 결합될 때 더 의미있는 정보가 전달되도록 한다.

그림 4에서 Conv3D ①은 그림 3의 하단에 굵은 실선으로 표현된 부분에 해당하며 Conv3D ②는 그림 3 상단의 점선으로 표현된 부분에 해당한다. Residual Block은 두 개의 3D 합성곱과, 배치 정규화, ReLU 활성화 함수, 드롭아웃, SEN Block으로 구성되며, 스킵 연결을 통해 기울기 소실 문제를 완화한다. 잔차 연결은 1x1x1 convolution과 batch normalization으로 설계하였다. 센서 데이터의 공간적 특성과 시계열 데이터의 시간적 특성을 고려하여 TCN에 3D 합성곱을 도입하였다. 이는 화재 확산의 시공간적 특성을 동시에 고려하여 보다 정밀하게 모델링하기 위함이다.

Residual 블록의 합성곱 레이어는 인과적 합성곱(casual convolution)과 확장 합성곱(dilated convolution)을 포함하는 확장 인과 합성곱(dilated causal convolution)을 적용하여 현 시점에서 과거 데이터의 장기 의존성을 확대할 수 있다. 또한, 각 블록의 합성곱 레이어는 시간 축으로 확장(dilation)되며 확장 계수(dilation factor)는 2의 거듭제곱으로 계층별로 증가하도록 그림 5와 같이 설계되었다. 커널 크기는 3으로 설정하였으며, 이를 통해 총 4 계층의 잔차 블록을 쌓아 각각의 계층에서 각각 8, 16, 32, 64개의 합성곱 채널로 사용하였다. 각 계층의 확장 계수와 커널 크기를 고려할 때, 총 수용 영역(Receptive Field)은 31(식 (1)에서  $n=4$ 일 때)로 계산된다. 이를 통해 적은 레이어 수로도 장기 의존성을 효과적으로 포착할 수 있다.




Fig. 5. TCN structure with Dilated Convolution.  
그림 5. Dilated Convolution을 갖는 TCN 구조

$$Receptive\ Field = 1 + \sum_{i=0}^{n-1} (kernel\ size - 1) \times dilation_i \quad (1)$$



이러한 3D TCN 구조는 화재 진행에 있어 중요한 시간적 패턴과 공간적 패턴을 동시에 학습할 수 있어, 센서 데이터의 시공간적 상관관계를 효과적으로 모델링한다. 특히 화재와 같이 시간에 따라 급격히 변화하며 공간적으로 확산되는 현상에 대한 예측을 수행하는 모델로써 적합하다.

#### 4.3. 화재 모델의 신경망 설계

신경망은 standard scaler를 적용하여 평균 0, 표준편차 1로 전처리된 70개의 센서 데이터가 1초 간격으로 30초 분량이 그림 6의 TCN+SEN 레이어로 입력된다. TCN+SEN 내부에서는 그림 4에서 설명한 바와 같이, 3D 확장 합성곱을 활용한 잔차 블록을 통해 시공간적 특징을 추출한다. 이때 모델은 총 4개의 잔차 블록을 거치면서 점진적으로 깊은 특징을 추출하고, 최종 시간 단계에서 추출된 특징 맵이 다음 단계로 전달된다.

이후 완전 연결 레이어를 통해 입력 특징을 고해상도 형태로 변환하고, 전치 합성곱을 거쳐 공간적 해상도를 확장한다. 이어지는 합성곱 레이어를 통해 추가적인 특징을 추출한 뒤, 마지막으로  $1 \times 1$  합성곱을 적용하여 각 구역의 세밀한 특징을 강조함으로써 최종 출력을 도출한다.




Fig. 6. Neural Network Structure with TCN+SEN.

그림 6. TCN+SEN을 적용한 신경망 구조

### V. 학습 및 측정결과

#### 5.1. 실험 환경 및 설정

설계된 화재 예측 신경망 모델을 학습하기 위한 데이

터는 총 18,000개이다. 데이터는 20개 발화지점과 각 발화지점에서 10가지의 열방출을 그리고, 90초 진행 시나리오를 기반으로 개발되었다. 테스트 데이터는 7개 발화지점과 각 3가지 열방출 및 90초 시나리오로 총 1,890개로 하였다.

학습 손실 함수로는 MAE(Mean Absolute Error), MSE(mean squared error), ANOVA(ANalysis Of VAriance)를 비교 평가하였고 MSE가 다소 우위를 보였다. 신경망에서는 온도, CO, 가시성이 출력되기 때문에 세 가지 손실을 균등하게 나누어 MSE에 적용하였다.

#### 5.2. 성능 비교

설계된 화재 예측 신경망 모델의 성능을 평가하기 위해 기존 LSTM 모델, ConvLSTM 모델, TCN 모델, 그리고 제안하는 TCN+SEN 모델의 성능을 비교하였으며 표 1에 수록하였다.

Table 1. Accuracy comparison of fire prediction neural network models.

표 1. 화재 예측 신경망 모델별 정확도 비교

Model	R <sup>2</sup>	RMSE
<b>TCN + SEN avg.</b>	0.8820	0.2572
-Temperature	0.8953	0.3612
-CO Fraction	0.8502	0.3612
-Soot Visibility	0.9006	0.1312
<b>TCN only avg.</b>	0.8822	0.2588
-Temperature	0.8901	0.2862
-CO Fraction	0.8472	0.3649
-Soot Visibility	0.9093	0.1253
<b>LSTM avg.</b>	0.8299	0.3026
-Temperature	0.8623	0.3203
-CO Fraction	0.8049	0.4123
-Soot Visibility	0.8224	0.1754
<b>ConvLSTM avg.</b>	0.8419	0.2980
-Temperature	0.8589	0.3242
-CO Fraction	0.7990	0.4185
-Soot Visibility	0.8677	0.1514

본 논문의 신경망 모델은 화귀 값을 예측하는 측면이 강하기 때문에 모델이 예측한 값과 실제 관측값 간의 분산의 비율을 설명하는 결정계수(Coefficient of Determination)로 성능 비교가 적절하다. 실험의 평균 결과로 TCN+

SEN은 LSTM 대비  $R^2$  기준으로 약 6.3%, RMSE 기준으로 약 17.7% 향상된 성능을 나타냈다.

예측값을 항목별로 살펴보면, 온도 예측에서 TCN+SEN은  $R^2$  점수가 LSTM보다 3.8% 높은 성능을 보였으며, CO 농도 예측에서도 TCN+SEN은 LSTM보다  $R^2$  점수가 약 5.6% 향상된 성능을 보였고, 연기 가시성 예측에서는 TCN+SEN이  $R^2$  점수 9.5% 높은 성능을 기록했다.

다른 비교 모델인 ConvLSTM과 비교해도 TCN+SEN은  $R^2$  점수, RMSE가 각각 4.9%, 15.9% 높은 성능을 기록했다. 모든 세부 항목에서도 TCN+SEN은 ConvLSTM보다 각각 4.2%, 6.4%, 3.2% 높게 성능을 보였다.

표 2를 보면 흥미롭게도, 본 연구의 TCN+SEN 모델은 훈련 시 사용된 30초의 시계열 길이보다 짧은 10초 입력 길이에 대해서도  $R^2$ , RMSE 손실이 적음을 보여준다. 이러한 결과는 TCN+SEN의 주요 장점 중 하나인 가변 길이 처리 능력을 잘 보여준다.

본 논문에서 제안하는 TCN+SEN의 예측 속도를 다른 모델과 비교하면 표 2와 같다. 화재 발생 후 10초에서 측정된 예측 정확도  $R^2$  값을 화재 발생 후 30초 값과 비교하였을 때 TCN only는 38%, ConvLSTM은 34.8% 감소한 반면 TCN+SEN은 8% 만 감소하였다. 이 결과는 화재 발생 후 10초부터 대피 경로 예측이 충분히 정확하다는 것을 보여준다.

Table 2. Comparison of prediction accuracy by neural network structure according to time elapsed after fire occurrence.

표 2. 화재 발생 후 경과된 시간에 따른 신경망 구조별 예측 정확도 비교

Model	$R^2$	RMSE
TCN + SEN, 30sec	0.8820	0.2572
TCN + SEN, 20sec	0.8736	0.2731
<b>TCN + SEN, 10sec</b>	0.8110	0.3487
TCN only, 30sec	0.8822	0.2588
TCN only, 20sec	0.8592	0.3905
<b>TCN only, 10sec</b>	0.5442	0.5191
ConvLSTM, 30sec	0.8419	0.3242
ConvLSTM, 20sec	0.8010	0.3481
<b>ConvLSTM, 10sec</b>	0.5487	0.5343

본 논문에서는  $R^2$  값의 비교뿐만 아니라 TCN+SEN의 출력값을 화재 발생 후 10초, 20초, 30초 간격으로 이미지화 하고 이를 label 이미지와 비교하였다.

그림 7은 온도, CO 농도, Soot visibility(그을음 가시성)의 10초, 20초, 30초에서 출력 이미지와 label 이미지를 보여준다. 비교 결과 10초에서 예측된 결과가 20초, 30초 결과와 유사하여 10초에서도 대피 경로가 예측됨을 알 수 있다.

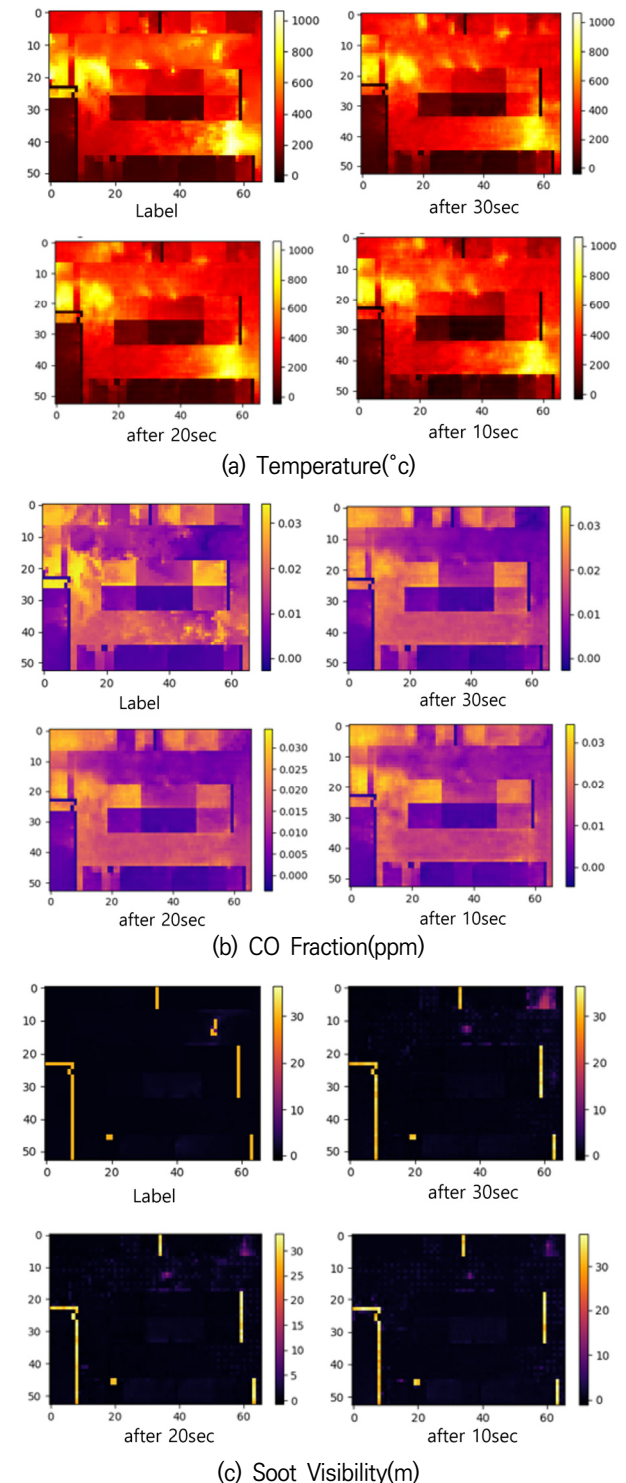


Fig. 7. Neural network prediction output image according to the time elapsed after the fire occurred.

그림 7. 화재 발생 후 경과된 시간에 따른 신경망 예측 출력 이미지

## VI. 결론

본 논문의 결과는 제한된 시간 동안 수집된 데이터만으로 화재 확산의 향후 상태를 예측할 수 있음을 시사하며, 이는 실시간 화재 대응 시스템에서 중요한 부분이다.

빠른 화재 예측의 정확도를 높이기 위해 장기 의존성 확대와 특징 맵의 동적 조정이 가능한 TCN+SEN 모델을 제안하였다. 그 결과 은닉 상태에 기반하는 기존의 시계열 신경망 모델에 비해 빠른 속도로 화재 확산을 예측하고 빠른 대피 경로를 제시할 수 있게 되었다.

기존 LSTM모델과 달리 TCN+SEN은 고정된 시계열 길이에 제약받지 않고 다양한 길이의 입력에 유연하게 대응할 수 있다. 특히 실제 화재 상황에서는 센서 데이터의 수집 기간이 가변적일 수 있으므로, 이러한 TCN+SEN의 특성은 실용적인 관점에서 매우 중요하다.

향후, 본 연구의 결과를 활용하여 보다 안전한 대피 경로를 제시하는 신경망 모델을 개발하기 위해서는 실제 화재 현장에서 얻어지는 데이터와 오차를 최소화한 시뮬레이터의 개발이 필요하다.

## References

- [1] Ryu J., Kwak D., "A Study on a Complex Flame and Smoke Detection Method Using Computer Vision Detection and Convolutional Neural Network," *Journal of Fire, MDPI*, Vol.5, No.4, 2023. DOI: 10.3390/fire5040108
- [2] Jun Seon Choi, Young Hoon Joo, "Fire Detection Method Using CCTV-based Flame Features and Density-based Spatial Clustering," *The Transactions of the Korean Institute of Electrical Engineers*, Vol.71, No.4, pp.656-662, 2022. DOI: 10.5370/KIEE.2022.71.4.656
- [3] Fang Xu, Xi Zhang, Tian Deng, Wenbo Xu, "An Image-Based Fire Monitoring Algorithm Resistant to Fire-like Objects," *Journal of Fire, MDPI*, Vol.7, No.1, 3, 2024. DOI: 10.3390/fire7010003
- [4] Lu Zhang, Like Mo, Cheng Fan, Haijun Zhou, Yangping Zhao, "Data-Driven Prediction Methods for Real-Time Indoor Fire Scenario Inferences," *Journal of Fire, MDPI*, Vol.6, No.10, 2023. DOI: 10.3390/fire6100401
- [5] Kwang-Yeob Lee, Jeong-Seok Kim, Jun-Mo Jeong, "Fire spreading prediction based on spatio-temporal neural network model," *Journal of Inst.*

*Korean.electr.electron.eng.*, Vol.29, No.1, pp.101-107, 2025. DOI: 10.7471/ikeee.2025.29.1.101

[6] Renzhuo Wan, Shuping Mei, Jun Wang, Min Liu, Fan Yang, "Multivariate Temporal Convolutional Networ: A Deep Neural Networks Approach for Multivariiate Time Series Forecasting," *Electronics, MDPI*, Vol.8, No.8, pp.876, 2019.

DOI: 10.3390/electronics8080876

[7] Saroj Gopali, Faranak Abri, Sima Siami-Namini, Akbar Siami Mamin, "A Comparison of TCN and LSTM Models in Detecting Anomalies in Time Series Data," *IEEE International Conference on Big Data*, Vol.1, pp.2415-2420, 2021.

DOI: 10.1109/BigData52589.2021.9671488

[8] John Burge, Matthew Bonanni, Matthias Ihme, Lily Hu, "Convolutional LSTM Neural Networks for Modeling Wildland Fire Dynamics," pp.06679, 2021. DOI: 10.48550/arXiv.2012.

[9] Spyros Kondylatos, Ioannis Prapas, Michele Ronco, Ioannis Paputsis, Gustau Camps-Valls, Maria Piles, Miguel-Angel Fernandez-Torres, Nuno Carvalhais, "Wildfire Danger Prediction and Understanding with Deep Learning," *Geophysical Research Letters*, AGU, Vol.49, No.17, e2022GL099368, 2022.

[10] Yheng Ji, Dan Wang, Qingliang Li, Taihui Liu, Yu Bai, "Global Wildfire Danger Predictions Based on Deep Learning Taking into Account Static and Dynamic Variables," *Forests, MDPI*, Vol.15, No.1, pp.216, 2024.

DOI: 10.3390/f15010216

## BIOGRAPHY

### Kwang-Yeob Lee (Life Member)



1985 : BS degree in Electronics Engineering, Sogang University  
 1987 : MS degree in Electronics Engineering, Yonsei University.  
 1994 : PhD degree in Electronics Engineering, Yonsei University.  
 1989~1995.2 : Senior Researcher, Hyundai Electronics Inc.

1995.3~present : Professor, Dept. of Computer Engineering, Seokyeong University



**Min-Hyung Kim** (Member)



2026 : BS degree candidate in  
Computer Engineering, Seokyeong  
University.

**Jun-Mo Jeong** (Member)



1985: BS degree in Electronics  
Engineering, Hanyang University.  
1987: MS degree in Electronics  
Engineering, Hanyang University.  
1992: PhD degree in Electronics  
Engineering, Hanyang University.  
1995~presently: Professor in  
Seokyeong University

Main interesting field: Micro Processor, AI,  
Integrated Circuit, Circuit Design & Test